

NAN 2026 · GAME AI SUBMISSION

# 얼음, 땡! AI 활용 기술 문서

생성 모델은 추천하고, 서버 규칙은 판정한다.



음성 협동형 학교 탈출 호러 · PC Web · 10-15분

FINAL AI TECHNOLOGY · FINAL · 2026.08.10

NAN 2026 사전과제 제출용 문서 버전: 1.0 / 2026-08-10 실행 환경: PC Web + FastAPI WebSocket + 선택적 로컬 Ollama

## 1. 기술 요약

『얼음, 땀!』의 AI는 대사를 꾸미는 부가기능이 아니라 플레이 규칙을 만드는 핵심 시스템이다. 게임은 인간의 실제 대화를 관찰해 비공개 금기어를 만들고, 두 AI 동료가 각자의 기억과 목표로 행동하며, 술래가 시야와 소리를 결합해 인간과 AI를 사냥하도록 구성한다.

가장 중요한 설계 원칙은 생성 모델과 게임 권위의 분리다. 로컬 LLM은 관찰된 후보의 순위를 추천하거나 자연스러운 표현을 만드는 역할만 수행한다. 금기어 적용, 이동, 포획, 빙결, 구조, 미션 성공, 주문과 탈출은 모두 서버의 결정론적 규칙이 확정한다. 따라서 Ollama가 없거나 응답이 실패해도 게임은 끝까지 진행된다.

## 2. 전체 아키텍처

브라우저 음성 인식 또는 텍스트 입력  
→ WebSocket 확정 발화 전송  
→ 서버 정규화·형태소 분석  
→ 비공개 동적 금기어 프로필  
→ 인간 빙결 및 술래 소리 신호  
→ AI 동료·술래 의사결정  
→ 서버 권위 상태 동기화  
→ 3D 월드·HUD·자막·사운드 피드백

| 계층        | 기술                                                | 책임                         |
|-----------|---------------------------------------------------|----------------------------|
| 클라이언트     | React, TypeScript, Three.js, R3F, Rapier, Zustand | 입력, 3D 표현, HUD, 음성·텍스트 UX  |
| 실시간 통신    | FastAPI WebSocket                                 | 방, 이벤트, 권위 상태 브로드캐스트       |
| 언어 분석     | Kiwi, 자모·편집거리 규칙                                  | 명사 후보, 활용형·복합어·유사 발음 판정    |
| 선택적 생성 AI | Ollama <a href="#">gemma3:4b</a>                  | 관찰 후보 순위 추천, 표현 다양화        |
| 게임 AI     | 서버 상태기계·효용 비교                                     | 동료 목표, 구조, 위험 회피, 술래 사냥    |
| 물리·공정성    | 서버 이동·LOS·충 계약                                    | 순간이동, 벽 너머 포획, 미완료 충 진입 방지 |

## 3. 비공개 동적 금기어

### 3.1 관찰과 첫 활성화

- 인간의 확정 발화만 프로필 자료로 사용한다.
- 첫 유효 발화 3개는 안전하게 관찰한다.
- Kiwi로 일반명사와 고유명사를 추출하고, 길이·보호어·중복 조건을 통과한 단어만 후보가 된다.
- 현재 충 미션 어휘에는 가중치를 더한다. 반복해서 쓰는 단어와 방송실·열쇠·인터폰·CCTV 같은 실제 미션 대화가 교차할 수록 우선 후보가 된다.
- LLM은 서버가 추출한 후보 밖의 단어를 만들 수 없다.

- 첫 세트는 분석 완료 후 다음 발화부터 적용되어 소급 빙결이 발생하지 않는다.

## 3.2 공정한 세대 교체

- 현재 세트 활성화 뒤 유효 발화 5개와 최소 45초를 모두 만족해야 갱신할 수 있다.
- 최근 발화는 최대 20개까지만 유지한다.
- 세 단어를 모두 바꾸지 않고 이전 세대에서 최소 한 단어를 유지한다.
- 한 번의 갱신에서 최대 두 단어만 교체한다.
- 파이널 진입 시 프로필을 잠그며 최종 주문은 금기어 판정에서 보호한다.

## 3.3 정보 비대칭

플레이 중 인간에게는 **관찰 중, 활성화, 변화, 봉인** 상태만 보여준다. 단어와 개수, 적중 단어는 공개하지 않는다. AI 동료는 현재 세트를 알고 발화 전에 위험 표현을 일반적인 지시어로 치환하지만 원문 글자, 길이, 동의어를 노출하지 않는다. 결과 화면에서만 세대별 단어, 적용 시간, 위반과 난도 영향을 공개한다.

# 4. 한국어 판정 파이프라인

- 1 브라우저의 최종 STT 전사 또는 Enter 텍스트 입력을 받는다.
- 2 공백과 표면형을 정규화한다.
- 3 정확 어절과 복합어를 우선 검사한다.
- 4 Kiwi 형태소 분석으로 활용형과 조사를 분리한다.
- 5 자모 분해와 편집거리로 발음이 가까운 표현을 보조 판정한다.
- 6 높은 신뢰도만 즉시 빙결시키고, 낮은 신뢰도는 표현 변경 안내로 처리한다.

고정 정답 문자열, 구조·탈출 명령과 최종 주문 어휘는 보호어 집합으로 관리한다. 반면 방향, 재질, 장치와 장소 표현은 미션 관련 후보가 될 수 있어 플레이어가 동의어와 특징 묘사를 사용하게 한다. 생성 모델의 추천보다 게임 완주 가능성을 우선하되, 미션과 무관한 금기어만 생기는 문제도 막는다.

# 5. AI 동료 두 명

각 AI 동료는 위치, 시야, 조사 기록, 플레이어 지시, 술래의 마지막 목격, 위험도, 구조 요청, 현재 목표와 목표 유지 시간을 별도로 가진다. 두 AI는 같은 후보를 선택할 수도 있으며, 스크립트로 역할을 강제하지 않는다.

## 5.1 행동 후보와 우선순위

- 보이는 술래 회피와 최근 목격 위치 회피
- 빙결된 팀원 구조
- 플레이어의 구체적인 조사 지시 수행
- 현재 총 미션 참여와 다음 목표 탐색
- 다른 층으로 이동한 플레이어 추종 또는 현재 임무 유지
- 파이널 장치·게이트 도달과 개별 탈출

서버는 후보 행동의 위험, 거리, 임무 가치와 기억을 비교해 목표를 선택한다. 목표를 짧은 주기로 무작위 변경하지 않도록 유지 시간을 둔다. 다만 구조 반경 가까이에서 인간이 금기어로 얼면 구조가 위험 회피보다 우선한다. 먼 거리에서는 술래 경로를 피하며 접근해 협동 장면이 실제 플레이로 이어진다.

## 5.2 설명 가능한 이해와 오해

플레이어가 금기어 대신 색, 모양, 재질, 쓰임새를 설명하면 모든 후보를 같은 입력으로 점수화한다. 최고 후보와 차점 후보의 점수 차가 충분하면 행동하고, 비슷하면 확인 질문을 한다. 이 점수와 선택 이유가 서버 이벤트에 포함되므로 AI의 오해와 교정 과정이 플레이로 보인다.

## 5.3 발화 안전

AI 발화는 관찰 보고, 판단 설명, 확인 질문, 행동 선언, 금기어 회피 의도로 구조화된다. 술래 거리와 긴급도에 따라 짧은 반응, 보통 말, 속삭임, 외침, 인터폰, 무전, 침묵 모드를 선택하며 모드별 소리 반경이 실제 술래 감지에 반영된다. 같은 정보는 일정 시간 반복하지 않고 구조·위험 발화를 우선한다.

# 6. 술래 AI와 AI 디렉터

술래는 살아 있는 인간과 AI 전체를 후보로 보고 거리, 가시선, 최근 목격, 소리 신호, 빙결 상태와 탈출구 위험을 비교한다.

탐색 → 소리 조사 → 흔적 수색 → 발견 → 추격  
→ 시야 상실 지점 수색 → 재탐색

- 옥상에서는 포획이 비활성이다.
- 3층에서 첫 술래가 제한적으로 등장한다.
- 2층부터 기본 사냥 능력을 전부 사용한다.
- 1층에서는 직접 추격형과 길목 차단형 두 술래가 협공한다.
- 파일널에서는 시간 강화 갱신을 멈추고 확정된 최고 난도로 게이트를 압박한다.

인간 화면의 붉은 경보와 사이렌은 같은 층 술래가 약 8.5m 안에 있거나 인간을 직접 발견·추격할 때만 활성화된다. 술래가 AI 동료를 쫓거나 다른 층에 있을 때는 인간에게 전면 경보를 주지 않아 위치 정보의 의미를 보존한다. 술래 모델에는 맥동하는 어둠, 늘어진 그림자와 발광 눈을 더해 실루엣만으로도 위화감을 전달한다.

AI 디렉터는 경과 시간, 층 진행, 미션 진척, 빙결 인원과 누적 금기어 위반을 입력으로 받아 허용 범위 안에서 속도·청각·시야 배율을 조정한다. 빙결자가 많을 때는 압박을 낮춰 회복 가능성을 보존한다. 누적 위반은 1·2·3회부터 경고·격앙·극한 단계로 즉시 상승한다. 첫 위반부터 속도 1.10배가 적용되고, 두 번째에는 속도 1.25배와 청각, 세 번째에는 속도 1.35배와 시야·최근 위치 추적이 강화된다.

## 7. 서버 권위와 공정성

| 위험             | 서버 방어                     |
|----------------|---------------------------|
| 클라이언트 순간이동     | 시간 간격과 최대 속도로 이동 샘플 검증    |
| 벽 너머 포획·구조     | 구조물 충돌과 층별 가시선 검사         |
| 미션 건너뛰기        | 현재 층·단계·상호작용 위치 검증        |
| 단서 없는 주문 성공    | 획득 조각, 순서, 퍼지 일치 조건 동시 검증 |
| 생성 AI 환각       | 관찰 후보 허용 목록과 결정론적 최종 판정   |
| AI 장애로 진행 중단   | 로컬 순위·규칙 기반 행동 폴백         |
| 구형 클라이언트 규칙 우회 | 폐기한 온보딩·공개 금기어 메시지 명시 거부  |

미션 역시 자유 생성 결과를 직접 실행하지 않는다. 라운드마다 서버가 시드를 발급하고 검증된 템플릿 안에서 옥상 신호 순서, 3층 증거 위치, 2층 기호 조합, 1층 관제 경로, 파이널 분기와 장치 순서를 바꾼다. 클라이언트에는 시드와 **매 판 새 구성** 상태만 공개하고 정답은 보내지 않는다.

클라이언트는 표현과 입력을 담당하고 성공 여부를 선언하지 않는다. 방, 층, 문, 위치, AI, 술래, 금기어, 빙결, 구조, 주문과 탈출 상태는 단일 FastAPI 서버가 소유한다.

## 8. 로컬 AI와 장애 대응

Ollama는 기본적으로 <http://127.0.0.1:11434>의 `gemma3:4b`를 사용하며 환경 변수로 주소, 모델과 제한시간을 바꿀 수 있다. 응답은 JSON으로 제한하고 다음 검증을 통과해야 사용한다.

- 서버가 실제 인간 발화에서 추출한 후보인가
- 보호어가 아닌가
- 두 글자 이상이며 중복이 아닌가
- 현재 세대 유지·최대 교체 수 계약을 지키는가

연결 실패, 시간 초과, 잘못된 JSON, 허용 목록 밖 출력은 모두 로컬 빈도·최근성 순위로 즉시 폴백한다. 따라서 심사 환경에 Ollama가 없어도 음성·텍스트 입력, 금기어, AI 동료, 술래와 전체 탈출 흐름은 동작한다.

## 9. 검증 전략과 결과

| 검증 범위              | 제출 기준 결과                                               |
|--------------------|--------------------------------------------------------|
| 서버 단위·통합·WebSocket | 393개 테스트 통과                                            |
| 비공개 금기어            | 관찰, 원자 적용, 교체 제한, 파일널 봉인, 비노출 검증                       |
| AI 동료              | 독립 목표, 위험 회피, 구조, 층 이동, 예외 복구 검증                       |
| 술래                 | 시아·청각·LOS, 인간·AI 포획, 2인 협공, 게이트 압박 검증                  |
| 수직 진행              | 옥상 → 3층 → 2층 → 1층 → 두 파일널 전이 검증                        |
| 클라이언트              | TypeScript production build·lint·학교 계약 통과              |
| 배포                 | Docker clean build, HTTP health·정적 페이지·WebSocket 왕복 통과 |
| 브라우저               | 옥상부터 3층 금기어 빙결·AI 구조, 2층·1층·파일널·탈출까지 실제 완주             |

## 10. AI가 만든 플레이 가치

『얼음, 땀!』에서 같은 플레이어라도 한 판 동안 사용한 말에 따라 위험 단어가 달라지고, AI 동료의 관찰과 오해, 술래의 기억과 소리 판단에 따라 동선이 달라진다. 생성 모델은 이 변화를 보조하지만 게임의 공정성과 완주 가능성은 검증 가능한 서버 규칙이 책임진다.

결과적으로 AI는 정답을 말해주는 NPC가 아니라 플레이어의 언어를 위험으로 바꾸고, 불완전하게 협력하며, 그 협력 소리 자체가 새로운 위험을 만드는 시스템으로 사용된다.